

L'Algebra Relazionale

[alcune slide tratte da <http://www-db.disi.unibo.it/courses/SIG/algebra2.pdf>
e <https://dbdmg.polito.it/wordpress/wp-content/uploads/2010/12/2.2-AlgebraRelazionale-PS.pdf>]

Linguaggi di interrogazione per il modello relazionale

- Un linguaggio di interrogazione (*query language*) per il modello relazionale è un linguaggio specializzato per manipolare (tipicamente estrarre) dati di una base di dati relazionale
- Tali linguaggi possono essere distinti in:
 - **Procedurali**: ogni interrogazione descrive passo a passo cosa fare per ottenere la risposta desiderata
 - **Dichiarativi**: l'interrogazione descrive il risultato desiderato, senza però descrivere cosa deve essere fatto per ottenere la risposta
- L'Algebra Relazionale (AR) è un linguaggio procedurale

Perché studiare l'Algebra Relazionale?

- **Fondamenta teoriche per le operazioni sui dati**
 - Base teorica solida per comprendere e utilizzare le operazioni fondamentali sui dati
- **Ottimizzazione delle query**
 - Ottimizzazione delle query per migliorare le prestazioni del database
- **Portabilità tra sistemi di database**
 - L'algebra relazionale è un modello teorico che non dipende da un particolare sistema di gestione di database (DBMS)
- **Comprensione degli algoritmi di esecuzione**
 - Comprendere come i DBMS eseguono fisicamente le operazioni sui dati

AR: concetti generali

- In AR, input e output di ogni interrogazione sono *relazioni* (nel senso del modello relazionale)
- Il risultato di un'operazione è una *nuova relazione*, che viene generata a partire da una o più relazioni in *input*
- Questa proprietà rende l'AR un'algebra “chiusa”
 - Tutti gli oggetti in AR sono relazioni

AR: concetti generali (cont.)

- Le relazioni ottenute da una qualsiasi operazione di AR possono a loro volta diventare input di nuove operazioni della stessa algebra
- Una sequenza di operazioni di AR forma un'**espressione di AR**. Per esempio:

$$\pi_{sname}(\pi_{sid}((\pi_{bid}\sigma_{color='red'}Boats) \bowtie Reserves) \bowtie Sailors)$$

- Il risultato di un'espressione di AR è a sua volta una relazione che rappresenta il risultato di un'interrogazione a una base di dati

Le operazioni dell'AR

■ Operazioni unarie

- SELECT (simbolo: σ (sigma))
- PROJECT (simbolo: π (pi greco))
- RENAME (simbolo: ρ (rho))

■ Operazioni insiemistiche di AR

- UNIONE ($\cup$), INTERSEZIONE ($\cap$), DIFFERENZA o SOTTRAZIONE ($-$)
- PRODOTTO CARTESIANO ($\times$)

■ Operazioni binarie

- JOIN
- DIVISIONE

■ Altre operazioni (che vedremo solo in parte)

- OUTER JOINS, OUTER UNION
- FUNZIONI AGGREGATE (come SUM, COUNT, AVG, MIN, MAX)

ESEMPIO

- Nel seguito useremo il seguente schema:

Sailors(sid: integer, sname: string, rating: integer, age: real)
Boats(bid: integer, bname: string, color: string)
Reserves(sid: integer, bid: integer, day: date)

assumendo che contenga i seguenti dati:

S1

<u>sid</u>	sname	rating	age
22	dustin	7	45.0
31	lubber	8	55.5
58	rusty	10	35.0

101	Interlake	blue
102	Interlake	red
103	Clipper	green
104	Marine	red

S2

<u>sid</u>	sname	rating	age
28	yuppy	9	35.0
31	lubber	8	55.5
44	guppy	5	35.0
58	rusty	10	35.0

R1

<u>sid</u>	<u>bid</u>	<u>day</u>
22	101	10/10/96
58	103	11/12/96

Selezione

- L'operatore di **selezione**, σ , permette di selezionare un **sottoinsieme delle tuple di una relazione**, applicando a ciascuna di esse una formula booleana F

Espressione: $\sigma_F(R)$

Schema	$R(X)$	X
Istanza	r	$\sigma_F(r) = \{ t \mid t \in r \text{ AND } F(t) = \text{vero} \}$
	Input	Output

- F si compone di **predicati** connessi da AND ($\wedge$), OR ($\vee$) e NOT ($\neg$)
- Ogni predicato è del tipo $A \theta c$ o $A \theta B$, dove:
 - A e B sono attributi in X
 - $c \in \text{dom}(A)$ è una costante
 - θ è un operatore di confronto, $\theta \in \{=, \neq, <, >, \leq, \geq\}$

SELECT: esempio

- Trovare in S2 tutti i SAILOR che hanno giudizi superiori a 8:

$$\sigma_{\text{rating} > 8}(S2)$$

- Risultato:

<u>sid</u>	sname	rating	age
28	yuppy	9	35.0
31	lubber	8	55.5
44	guppy	5	35.0
58	rusty	10	35.0



sid	sname	rating	age
28	yuppy	9	35.0
58	rusty	10	35.0

- Stesso numero di attributi, selezionate le due (sole) tuple che soddisfano la condizione specificata nel SELECT (ovvero *rating* > 8)

Proprietà dell'operatore SELECT

- $\sigma_{\langle \text{select_cond} \rangle}(R)$ produce una relazione S che ha lo stesso schema (cioè gli stessi attributi) di R
- SELECT è commutativo:
 - $\sigma_{\langle \text{cond1} \rangle}(\sigma_{\langle \text{cond2} \rangle}(R)) = \sigma_{\langle \text{cond2} \rangle}(\sigma_{\langle \text{cond1} \rangle}(R))$
- Di conseguenza, l'ordine di applicazioni non conta:
 - $\sigma_{\langle \text{cond1} \rangle}(\sigma_{\langle \text{cond2} \rangle}(\sigma_{\langle \text{cond3} \rangle}(R))) = \sigma_{\langle \text{cond2} \rangle}(\sigma_{\langle \text{cond3} \rangle}(\sigma_{\langle \text{cond1} \rangle}(R)))$
- Una sequenza di SELECT può essere sostituita da una singola operazione con congiunzione delle condizioni:
 - $\sigma_{\langle \text{cond1} \rangle}(\sigma_{\langle \text{cond2} \rangle}(\sigma_{\langle \text{cond3} \rangle}(R))) = \sigma_{\langle \text{cond1} \rangle \text{ AND } \langle \text{cond2} \rangle \text{ AND } \langle \text{cond3} \rangle}(R))$
- Il numero di tuple prodotte dal SELECT è $\leq$ al numero di tuple dell'istanza della relazione R in input

Selezione: esempi (1)

Esami

Matricola	CodCorso	Voto	Lode
29323	483	28	NO
39654	729	30	Sì
29323	913	26	NO
35467	913	30	NO
31283	729	30	NO

$\sigma_{(\text{Voto} = 30) \text{ AND } (\text{Lode} = \text{NO})}(\text{Esami})$

Matricola	CodCorso	Voto	Lode
35467	913	30	NO
31283	729	30	NO

$\sigma_{(\text{CodCorso} = 729) \text{ OR } (\text{Voto} = 30)}(\text{Esami})$

Matricola	CodCorso	Voto	Lode
39654	729	30	Sì
35467	913	30	NO
31283	729	30	NO

Selezione: esempi (2)

Partite	Giornata	Casa	Ospite	GolCasa	GolOspite
	4	Venezia	Bologna	0	1
	5	Brescia	Atalanta	3	3
	5	Inter	Bologna	1	0
	5	Lazio	Parma	0	0

$\sigma_{(\text{Giornata} = 5) \text{ AND } (\text{GolCasa} = \text{GolOspite})}(\text{Partite})$

Giornata	Casa	Ospite	GolCasa	GolOspite
5	Brescia	Atalanta	3	3
5	Lazio	Parma	0	0

$\sigma_{(\text{Ospite} = \text{Bologna}) \text{ AND } (\text{GolCasa} < \text{GolOspite})}(\text{Partite})$


Giornata	Casa	Ospite	GolCasa	GolOspite
4	Venezia	Bologna	0	1

Proiezione

- L'operatore di **proiezione**, π , è ortogonale alla selezione, in quanto permette di selezionare un **sottoinsieme Y degli attributi di una relazione**

Espressione: $\pi_Y(R)$

Schema	R(X)	Y
Istanza	r	$\pi_Y(r) = \{ t[Y] \mid t \in r \}$
	Input	Output



PROJECT: esempio

- Trovare nome e giudizio di tutti i SAILORS (istanza S2):

$\pi_{\text{sname}, \text{rating}}(\text{S2})$

- Risultato:

<i>sid</i>	<i>sname</i>	<i>rating</i>	<i>age</i>
28	yuppy	9	35.0
31	Lubber	8	55.5
44	guppy	5	35.0
58	Rusty	10	35.0



<i>sname</i>	<i>rating</i>
yuppy	9
Lubber	8
guppy	5
Rusty	10

PROJECT: proprietà

- La forma generale dell'operazione *project* è:
$$\pi_{\langle \text{lista_di_attributi} \rangle}(R)$$
 - π è l'operatore di proiezione
 - $\langle \text{lista_di_attributi} \rangle$ è la lista degli attributi di R che si vogliono mantenere nella relazione in output
- L'operatore PROJECT rimuove le tuple duplicate!!
 - Questo perché **il risultato del PROJECT deve essere un insieme di tuple**
 - Matematicamente, un insieme non ammette elementi duplicati!

PROJECT: proprietà

- Il numero di tuple in $\pi_{\langle list \rangle}(R)$ è uguale al numero di tuple di R o minore (se sono stati eliminati eventuali duplicati)
 - Se *list* include una *chiave* di R , allora il numero di tuple restituite da PROJECT sarà sempre *uguale* al numero di tuple di R
- **PROJECT non è commutativo!**
 - $\pi_{\langle list1 \rangle}(\pi_{\langle list2 \rangle}(R)) = \pi_{\langle list2 \rangle}(\pi_{\langle list1 \rangle}(R))$ solo se $\langle list2 \rangle$ contiene gli attributi di $\langle list1 \rangle$

Proiezione: esempi (1)

Corsi

CodCorso	Titolo	Docente	Anno
483	Analisi	Biondi	1
729	Analisi	Neri	1
913	Sistemi Informativi	Castani	2

$\pi_{\text{CodCorso, Docente}}(\text{Corsi})$

CodCorso	Docente
483	Biondi
729	Neri
913	Castani

$\pi_{\text{CodCorso, Anno}}(\text{Corsi})$

CodCorso	Anno
483	1
729	1
913	2

Proiezione: esempi (2)

Corsi	CodCorso	Titolo	Docente	Anno
	483	Analisi	Biondi	1
	729	Analisi	Neri	1
	913	Sistemi Informativi	Castani	2

$\pi_{\text{Titolo}}(\text{Corsi})$

Titolo
Analisi
Sistemi Informativi

$\pi_{\text{Docente}}(\text{Corsi})$

Docente
Biondi
Neri
Castani

Espressioni in AR


- E' possibile applicare in sequenza diversi operatori di AR:
 - Un'espressione può essere ottenuta:
 1. annidando (*nesting*) gli operatori in un'unica espressione, o
 2. applicando gli operatori uno alla volta, creando di volta in volta **relazioni intermedie** (vedremo come quando introdurremmo la ridenominazione)
- Nel secondo caso, dobbiamo assegnare nomi alle relazioni intermedie.

Espressioni in AR

$\pi_{sname, rating}(\sigma_{rating > 8}(S2))$



sid	sname	rating	age
28	yuppy	9	35.0
58	rusty	10	35.0



sname	rating
yuppy	9
rusty	10

Operazioni insiemistiche

- **UNIONE** ($R \cup S$): è la relazione che include tutte le tuple che sono in R o in S o in entrambe
 - I duplicati sono eliminati
- **INTERSEZIONE** ($R \cap S$): è la relazione che include tutte le tuple che sono sia in R sia in S
- **DIFFERENZA** ($R - S$): è la relazione che include tutte le tuple che sono in R ma non in S
 - Per convenzione, se i nomi degli attributi sono diversi in R e in S , l'output utilizza i nomi di R
- **PRODOTTO CARTESIANO** ($R \times S$): è la relazione che ha come schema l'unione degli attributi di R e S e una tupla $\langle r, s \rangle$ (la concatenazione di r e s) per ogni coppia di tuple $r \in R$ e $s \in S$

UNIONE, INTERSEZIONE, DIFFERENZA: compatibilità dei domini

NOTA BENE:

- Le relazioni in input R e S devono essere “compatibili”, ovvero:
 - R ed S devono avere lo stesso numero n di attributi
 - gli attributi corrispondenti di R e S devono avere lo stesso dominio (o domini compatibili)
$$\text{dom}(A_i) = \text{dom}(B_i) \text{ per } i=1, 2, \dots, n)$$

Esempi:

$S1$

<u>sid</u>	sname	rating	age
22	dustin	7	45.0
31	lubber	8	55.5
58	rusty	10	35.0

$S2$

<u>sid</u>	sname	rating	age
28	yuppy	9	35.0
31	lubber	8	55.5
44	guppy	5	35.0
58	rusty	10	35.0

INPUT

OUTPUT

sid	sname	rating	age
22	dustin	7	45.0
31	lubber	8	55.5
58	rusty	10	35.0
44	guppy	5	35.0
28	yuppy	9	35.0

$S1 \cup S2$

sid	sname	rating	age
31	lubber	8	55.5
58	rusty	10	35.0

$S1 \cap S2$

sid	sname	rating	age
22	dustin	7	45.0

$S1 - S2$

Unione e differenza: esempi

VoliCharter

Codice	Data
XY123	21/07/2001
SC278	28/07/2001
XX338	18/08/2001

VoliNoSmoking

Codice	Data
SC278	28/07/2001
SC315	30/07/2001

VoliCharter $\cup$ VoliNoSmoking

Codice	Data
XY123	21/07/2001
SC278	28/07/2001
XX338	18/08/2001
SC315	30/07/2001

VoliCharter - VoliNoSmoking

Codice	Data
XY123	21/07/2001
XX338	18/08/2001

VoliNoSmoking - VoliCharter

Codice	Data
SC315	30/07/2001

Alcune proprietà

- UNION e INTERSECTION sono operazioni *commutative*:
 - $R \cup S = S \cup R$ e $R \cap S = S \cap R$
- UNION e INTERSECTION sono operazioni *associative* e possono quindi essere pensate come operazioni *n-arie*:
 - $R \cup (S \cup T) = (R \cup S) \cup T$
 - $(R \cap S) \cap T = R \cap (S \cap T)$
- SET DIFFERENCE non è commutativa, per cui in generale:
 - $R - S \neq S - R$

Operazioni insiemistiche: il PRODOTTO CARTESIANO (cross product)

- Serve a combinare tuple di due relazioni e si indica con il simbolo $\times$

$$R(A_1, \dots, A_n) \times S(B_1, \dots, B_m)$$

- Il risultato è una nuova relazione Q di grado $n + m$:

$$Q(A_1, \dots, A_n, B_1, \dots, B_m)$$

con gli attributi esattamente in questo ordine


- Se R ha n_R tuple ($|R| = n_R$) e S ha n_S tuple ($|S| = n_S$), allora $R \times S$ avrà $n_R * n_S$ tuple ($|R \times S| = n_R * n_S$).

IL PRODOTTO CARTESIANO: esempio

<i>S1</i>	<u>sid</u>	sname	rating	age
	22	dustin	7	45.0
	31	lubber	8	55.5
	58	rusty	10	35.0

X

<i>R1</i>	<u>sid</u>	<u>bid</u>	<u>day</u>
	22	101	10/10/96
	58	103	11/12/96



S1 x R1

(sid)	sname	rating	age	(sid)	bid	day
22	dustin	7	45.0	22	101	10/10/96
22	dustin	7	45.0	58	103	11/12/96
31	lubber	8	55.5	22	101	10/10/96
31	lubber	8	55.5	58	103	11/12/96
58	rusty	10	35.0	22	101	10/10/96
58	rusty	10	35.0	58	103	11/12/96

L'operatore RENAME

- Nell'esempio di PRODOTTO CARTESIANO, è chiaro che c'è un conflitto di nomi tra gli attributi della relazione S1xR1 (sulla colonna *sid*)
- Per risolvere problemi di questo tipo, viene introdotto un operatore di ridenominazione (*rename*), denotato dal simbolo ρ (rho)

RENAME (cont.)

- L'operatore di ridenominazione (RENAME) ha la seguente forma:
 - $\rho(R(F_1, \dots, F_n), E)$ dove:
 - E è una qualunque espressione in algebra relazionale
 - R è una nuova relazione che ha le stesse tuple di E ma con alcuni attributi rinominati
 - $(F_1, \dots, F_n)$ è la *lista di ridenominazione* e contiene espressioni della forma *vecchionome* $\rightarrow$ *nuovonome* o *posizione* $\rightarrow$ *nuovonome*
- Se il nome degli attributi non viene modificato, si può omettere la lista di ridenominazione

Esempio di ridenominazione

S1 x R1

(sid)	sname	rating	age	(sid)	bid	day
22	dustin	7	45.0	22	101	10/10/96
22	dustin	7	45.0	58	103	11/12/96
31	lubber	8	55.5	22	101	10/10/96
31	lubber	8	55.5	58	103	11/12/96
58	rusty	10	35.0	22	101	10/10/96
58	rusty	10	35.0	58	103	11/12/96

$\rho(C(1 \rightarrow sid1, 5 \rightarrow sid2), S1 \times R1)$

sid1	sname	rating	age	sid2	bid	day
22	dustin	7	45.0	22	101	10/10/96
22	dustin	7	45.0	58	103	11/12/96
31	lubber	8	55.5	22	101	10/10/96
31	lubber	8	55.5	58	103	11/12/96
58	rusty	10	35.0	22	101	10/10/96
58	rusty	10	35.0	58	103	11/12/96

Operazioni insiemistiche: il JOIN

- L'operazione di JOIN di due relazioni R e S ($R \bowtie_c S$) può essere definita in termini di PRODOTTO CARTESIANO e SELEZIONE come segue:

$$\sigma_c(R \times S)$$

dove c è una condizione espressa con una formula booleana

- Il risultato è l'insieme delle combinazioni di tuple di R e S che soddisfano la condizione (il predicato) c
- Questa forma di JOIN (a.k.a. θ -join / theta-join) è la forma più generale e permette di combinare in modo semanticamente sensato tuple che appartengono a relazioni diverse

Alcune proprietà del JOIN

- Il JOIN è commutativo e associativo
- La cardinalità $| R \bowtie_c S |$ della relazione risultante dal JOIN sarà $\leq$ della cardinalità del prodotto cartesiano delle due relazioni ($|R \times S|$), grazie al fatto che alcune delle combinazioni di tuple di $R \times S$ potrebbero non rispettare la condizione c del JOIN (e normalmente è così!)

Esempio di JOIN

$S1 \times R1$

(sid)	sname	rating	age	(sid)	bid	day
22	dustin	7	45.0	22	101	10/10/96
22	dustin	7	45.0	58	103	11/12/96
31	lubber	8	55.5	22	101	10/10/96
31	lubber	8	55.5	58	103	11/12/96
58	rusty	10	35.0	22	101	10/10/96
58	rusty	10	35.0	58	103	11/12/96

$S1 \bowtie R1$
 $S1.sid < R1.sid$

(sid)	sname	rating	age	(sid)	bid	day
22	dustin	7	45.0	58	103	11/12/96
31	lubber	8	55.5	58	103	11/12/96

Variante 1: EQUIJOIN

- È la forma di JOIN più comunemente utilizzata
- La condizione c include **soltanto** confronti di uguaglianza (=)
- Esempio:

sid	sname	rating	age	bid	day
22	dustin	7	45.0	101	10/10/96
58	rusty	10	35.0	103	11/12/96

$$S1 \bowtie_{R.sid=S.sid} R1$$

- NB: la colonna usata nella condizione dell'EQUIJOIN compare solo una volta nel risultato (nella parte di tupla che appartiene alla relazione di sinistra)

Variante : il NATURAL JOIN

- Il NATURAL JOIN (denotato da $R \bowtie S$) è un EQUIJOIN in cui l'uguaglianza è automaticamente definita su **tutti** gli attributi comuni di R e S
- La definizione standard assume che tutte le coppie di attributi su cui si effettua il JOIN abbiano lo stesso nome in entrambe le relazioni (es. *S1.sid* e *R1.sid*)
- Se così non fosse, va applicata prima un'operazione di ridenominazione

Join naturale: definizione

- Ogni tupla che compare nel risultato del join naturale di r_1 e r_2 , istanze rispettivamente di $R_1(X_1)$ e $R_2(X_2)$, è ottenuta come combinazione (“match”) di una tupla di r_1 con una tupla di r_2 sulla base dell’uguaglianza dei valori degli attributi comuni (cioè quelli in $X_1 \cap X_2$)
- Inoltre, lo schema del risultato è l’unione degli schemi degli operandi

Espressione: $R_1 \bowtie R_2$		
Schema	$R_1(X_1), R_2(X_2)$	$X_1 X_2$
Istanza	r_1, r_2	$r_1 \bowtie r_2 = \{ t \mid t[X_1] \in r_1 \text{ AND } t[X_2] \in r_2 \}$
	Input	Output

Join naturale: osservazioni


- È possibile che una tupla di una delle relazioni operande non faccia match con nessuna tupla dell'altra relazione; in tal caso tale tupla viene detta “**dangling**”
- Nel caso limite è quindi possibile che il risultato del join sia vuoto; all'altro estremo è possibile che ogni tupla di r_1 si combini con ogni tupla di r_2
- Ne segue che
la cardinalità del join, $|r_1 \bowtie r_2|$, è compresa tra 0 e $|r_1| * |r_2|$
- Se il join è eseguito su una superchiave di $R_1(X_1)$, allora ogni tupla di r_2 fa match con al massimo una tupla di r_1 , quindi $|r_1 \bowtie r_2| \leq |r_2|$
- Se $X_1 \cap X_2$ è la chiave primaria di $R_1(X_1)$ e foreign key in $R_2(X_2)$ (e quindi c'è un vincolo di integrità referenziale) allora $|r_1 \bowtie r_2| = |r_2|$

Operazioni binarie: la DIVISIONE

- La DIVISIONE non è un operatore primitivo e non tutti i DBMS la supportano
- Tuttavia, può essere utile per rappresentare query del tipo:
Trovare i marinai che hanno prenotato tutte le barche
- Data una relazione A con due colonne x e y e B con una sola colonna y:

$$A/B = \{ \langle x \rangle \mid \exists \langle x, y \rangle \in \tilde{A} \ \forall \langle y \rangle \in B \}$$

Esempio di DIVISIONE



OUTER JOIN


- Nel NATURAL JOIN e EQUIJOIN, le tuple che **non** soddisfano le condizioni del JOIN vengono eliminate dal risultato.
 - Anche le tuple con valore NULL negli attributi del JOIN sono eliminate → Perdita di informazione
- Per superare questo limite, sono state introdotte delle operazioni, chiamate OUTER JOIN, che servono a mantenere alcune (o tutte) le tuple che non hanno un *match* nelle altre forme di JOIN

OUTER JOIN

- Esistono 3 varianti dell'OUTER JOIN:
 - **LEFT OUTER JOIN:** vengono mantenute tutte le tuple del primo operando
 - **RIGHT OUTER JOIN:** vengono mantenute tutte le tuple del secondo operando
 - **FULL OUTER JOIN:** vengono mantenute le tuple di entrambi gli operandi
- In tutti e tre i casi, nella relazione risultante i valori mancanti sono sostituiti con il valore NULL

I tre tipi di OUTER JOIN

- Dal punto di vista insiemistico, possiamo rappresentare come segue l'OUTER JOIN nelle sue possibili varianti:



Outer join: esempi

Ricercatori

Nome	CodProgetto
Rossi	HK27
Bianchi	HK27
Verdi	HK28

Progetti

CodProgetto	Responsabile
HK27	Bianchi
HAL2000	Neri

Ricercatori $\Rightarrow \Leftarrow$ Progetti

Nome	CodProgetto	Responsabile
Rossi	HK27	Bianchi
Bianchi	HK27	Bianchi
Verdi	HK28	NULL

Ricercatori $\Rightarrow \Leftarrow =$ Progetti

Nome	CodProgetto	Responsabile
Rossi	HK27	Bianchi
Bianchi	HK27	Bianchi
Verdi	HK28	NULL
NULL	HAL2000	Neri


Ricercatori $\triangleright \Leftarrow =$ Progetti

Nome	CodProgetto	Responsabile
Rossi	HK27	Bianchi
Bianchi	HK27	Bianchi
NULL	HAL2000	Neri

Query Tree

- E' una struttura dati interna per rappresentare i passi di esecuzione di una query
- Standard per stimare il lavoro necessario per eseguire una query, la generazione di risultati intermedi e l'ottimizzazione dell'esecuzione
- I nodi stanno per le operazioni (selezione, proiezione, join,)
- Le foglie rappresentano la/le relazione/i di partenza
- Un albero dà una buona rappresentazione visiva della complessità della query e delle operazioni coinvolte

Esempio di Query Tree




A quale domanda corrisponde questo Query Tree?

Ottimizzazione algebrica dell'esecuzione di una query

- Obiettivo: minimizzare i costi di esecuzione di una query
- Si parte da un piano di esecuzione (rappresentato da un query tree)
- Si verifica se esista un altro piano di esecuzione che
 - produca lo stesso risultato di quello originale
 - abbia costi inferiori

Ottimizzazione di esecuzione di query

- Possiamo ottimizzare il piano di esecuzione a sinistra?



- Perché (intuitivamente) il piano di esecuzione a destra è migliore di quello a sinistra?

Esempi di (semplici) regole di ottimizzazione

- **Anticipazione delle selezioni** (*push selections down*):
 - spostare le operazioni di **selezione** il più vicino possibile alle tabelle di origine → applicare i filtri subito riduce il numero di righe coinvolte nelle operazioni successive, come i join o le proiezioni
- **Anticipazione delle proiezioni** (*push projections down*):
 - eliminando le colonne non necessarie prima di effettuare altre operazioni riduce lo spazio di memoria necessario per memorizzare i dati temporanei
- **Riordino dei join**
 - spesso è possibile riordinare le operazioni di join per eseguire prima quelle che producono meno righe intermedie, riducendo il numero di combinazioni da elaborare